Projektaufgaben Block 3

Carlo Michaelis, 573479; David Hinrichs, 572347; Lukas Ruff, 572521 10 Januar 2017

1 SPAM vs. HAM: Naive Bayes

In dieser Aufgabe beschäftigen wir uns mit dem Spam vs. Ham Klassifizierungsproblem.

1.1 Einlesen der Daten

1.2 Erzeugen der Featurematrizen

1.3 Erzeuge Wahrscheinlichkeiten für den Naive-Bayes-Classifier

```
# Generate probabilites
indSpam <- as.logical(YTrain[[1]])
indHam <- !(YTrain[[1]])

phiSpam <- (colSums(XTrain[indSpam, ]) + 1) / (sum(XTrain[indSpam, ]) + nWords)
phiHam <- (colSums(XTrain[indHam, ]) + 1) / (sum(XTrain[indHam, ]) + nWords)</pre>
```

Zähler und Nenner wurden der
art angepasst, dass für den Fall, dass keine Trainingsdaten vorliegen, für die bedingten Verteilungen der Wörter in einem Dokument a priori diskrete Gleichverteilungen mit Wahrscheinlichkeiten $\frac{1}{|V|} = \frac{1}{2500}$ angenommen werden.

1.4 Vorhersage auf den Testdaten

```
# Prior probabilities of message being Spam or Ham are equal:
sum(indSpam) == sum(indHam)
## [1] TRUE
# Predict test labels (using logarithm)
postSpam <- rowSums(t(t(XTest) * log(phiSpam)))</pre>
postHam <- rowSums(t(t(XTest) * log(phiHam)))</pre>
predTest <- (postSpam > postHam) * 1
# Number of errors
sum(YTest[[1]] != predTest)
## [1] 6
# SPAM indicators
dict$word[rank(-phiSpam) <= 25]</pre>
##
  [1] s
                 email
                           address order
                                             report
                                                       mail
                                                                our
## [8] send
                 program d
                                    one
                                             list
                                                       name
                                                                receive
## [15] free
                 please
                                                                business
                          http
                                    work
                                             money
                                                       com
## [22] nt
                 internet day
                                    over
## 2500 Levels: a ability able above absolutely abstract abstracts ... zur
# HAM indicators
dict$word[rank(-phiHam) <= 25]</pre>
   [1] s
                    email
                                 address
                                             language
                                                          university
   [6] one
                    information please
                                             http
                                                          include
## [11] e
                    linguistic fax
                                                          de
                                             WWW
## [16] conference english
                                 workshop
                                                          word
                                             paper
## [21] research
                    edu
                                 abstract
                                                          submission
                                             papers
## 2500 Levels: a ability able above absolutely abstract abstracts ... zur
```