# Projektaufgaben Block 3

Carlo Michaelis, 573479; David Hinrichs, 572347; Lukas Ruff, 572521

10 Januar 2017

## 1 SPAM vs. HAM: Naive Bayes

In dieser Aufgabe beschäftigen wir uns mit dem Spam vs. Ham Klassifizierungsproblem.

#### 1.1 Einlesen der Daten

### 1.2 Erzeugen der Featurematrizen

## 1.3 Erzeuge Wahrscheinlichkeiten für den Naive-Bayes-Classifier

```
fnNBTrain <- function(X, Y) {
    # This function generates the probabilities for the Naive-Bayes-Classifier.
#
    # Args:
    # X: Matrix of features
# Y: Vector of labels
#
# Returns:
# A list containing the following elements:</pre>
```

```
$phiSpam:
                     Probabilities for words occuring in SPAM message
        $phiHam:
                     Probabilities for words occuring in HAM message
        $qammaSpam: The relative frequency of SPAM messages
  #
        $qammaHam: The relative frequency of HAM messages
  nWords <- length(Y)
  indSpam <- as.logical(Y)</pre>
  indHam <- !(indSpam)</pre>
  NBClass <- list()
  # Generate probabilities
  NBClass$phiSpam <- (colSums(X[indSpam, ]) + 1) / (sum(X[indSpam, ]) + nWords)</pre>
  NBClass$phiHam <- (colSums(X[indHam, ]) + 1) / (sum(X[indHam, ]) + nWords)
  # Get relative frequencies
  NBClass$gammaSpam <- sum(indSpam)</pre>
  NBClass$gammaHam <- sum(indHam)
  return(NBClass)
}
NBClass1 <- fnNBTrain(XTrain, YTrain[[1]])</pre>
```

Zähler und Nenner wurden der<br/>art angepasst, dass für den Fall, dass keine Trainingsdaten vorliegen, für die bedingten Verteilungen der Wörter in einem Dokument a priori diskrete Gleichverteilungen mit Wahrscheinlichkeiten  $\frac{1}{|V|} = \frac{1}{2500}$  angenommen werden.

### 1.4 Vorhersage auf den Testdaten

```
fnNBPredict <- function(X, NBClass) {</pre>
  # This function predicts one of the two classes (SPAM or HAM) for some test
  # data X using a Naive-Bayes-Classifier trained by fnNBTrain.
  # Args:
  # X:
                Matrix of features
    NBClass: A list returned by fnNBTrain which contains
                  $phiSpam: Probabilities for words occurring in SPAM message
  #
                              Probabilities for words occuring in HAM message
  #
                  $gammaSpam: The relative frequency of SPAM messages
                  $gammaHam: The relative frequency of HAM messages
  # Returns:
     A vector with predictions for each example.
  # Predict labels (using logarithm)
  postSpam <- rowSums(t(t(X) * log(NBClass$phiSpam))) + log(NBClass$gammaSpam)</pre>
  postHam <- rowSums(t(t(X) * log(NBClass$phiHam))) + log(NBClass$gammaHam)</pre>
 pred <- (postSpam > postHam) * 1
  return(pred)
}
```

```
# Predict test labels
predTest1 <- fnNBPredict(XTest, NBClass1)

# Number of errors
nErr1 <- sum(YTest[[1]] != predTest1)</pre>
```

Insgesamt gibt es lediglich 6 falsche Klassifikationen, was einer Fehlerrate von 2.31% entspricht.

Schauen wir uns an, welche Wörter besonders gute Indikatoren für SPAM oder HAM sind. Dazu betrachten wir jeweils die 25 Wörter mit den größten  $\Phi_{i|1}$  bzw.  $\Phi_{i|0}$ :



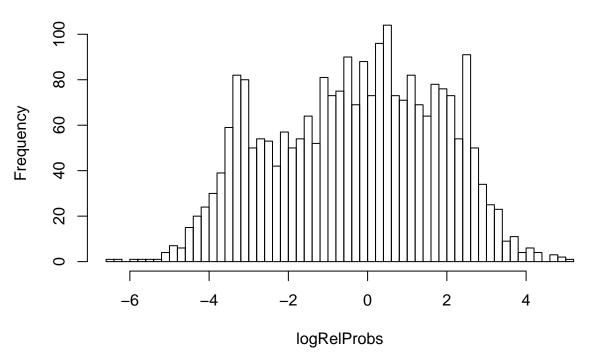
Figure 1: Wordclouds for SPAM (left) and HAM (right) indicators.

## 1.5 Feature Engineering

Für die Klassifizierung von SPAM und HAM bedeutunglose Wörter sollten in SPAM- und HAM-Nachrichten relativ betrachtet ähnlich häufig vorkommen. Um Ähnlichkeit zu quantifizieren, können wir das Verhältnis von  $\Phi_{i|1}$  zu  $\Phi_{i|0}$  betrachten. Logarithmieren liefert eine bessere Skalierung.

```
logRelProbs <- log(NBClass1$phiSpam/NBClass1$phiHam)
hist(logRelProbs, breaks = 50)</pre>
```

# **Histogram of logRelProbs**



```
# Remove some words
indMeaningful <- !((logRelProbs >= (-1.5)) & (logRelProbs <= 1.5))

# Test classification after removal of meaningless words
NBClass2 <- fnNBTrain(XTrain[, indMeaningful], YTrain[[1]])
predTest2 <- fnNBPredict(XTest[, indMeaningful], NBClass2)

# New classification error
nErr2 <- sum(YTest[[1]] != predTest2)</pre>
```

Durch die Entfernung bedeutungsloser Wörtern hat sich die Anzahl der Fehler von 6 auf 3 halbiert.

```
# TODO: Implementation of additional features (e.g. number of words in doc)
# Maybe hints on: https://en.wikipedia.org/wiki/Naive_Bayes_spam_filtering

# TODO: Implementation of m-fold cross validation
# Maybe plots for train/test error in dependence of training set size.
# Discussion on model generalization and overfitting.
```

# 2 SPAM vs. HAM: Lineare Regression & Lasso

```
fnLRPredict <- function(X, Y, XTest) {
    # This function predicts the labels for the test set using Lasso regression
    #
    # Args:</pre>
```

```
# X: Matrix of training features
  # Y: Vector of training labels
  # XTest: Vector of test features
  # Returns:
  # Vector of predicted labels from test features
  # fit spam data via lasso regularization and use binomial function
  fitGlm <- glmnet(X, Y, family = "binomial")</pre>
  {\it \# do\ cross\ validation\ to\ find\ optimal\ lambda}
  cv <- cv.glmnet(X, Y)</pre>
  # predict test data
  YPred <- predict(fitGlm, XTest, type="response", s=cv$lambda.min)</pre>
  # classify test data
  YPred[YPred >= 0.5] <- 1
  YPred[YPred < 0.5] <- 0</pre>
  return(YPred)
YPred <- fnLRPredict(XTrain, YTrain[[1]], XTest)</pre>
# error rate (compare predicted labels with true labels)
sum(YPred != YTest)/length(YTest[[1]])
```

## [1] 0.03461538