# Projektaufgaben Block 3

Carlo Michaelis, 573479; David Hinrichs, 572347; Lukas Ruff, 572521 10 Januar 2017

### 1 SPAM vs. HAM: Naive Bayes

In dieser Aufgabe beschäftigen wir uns mit dem Spam vs. Ham Klassifizierungsproblem.

#### 1.1 Einlesen der Daten

#### 1.2 Erzeugen der Featurematrizen

#### 1.3 Erzeuge Wahrscheinlichkeiten für den Naive-Bayes-Classifier

```
fnNBTrain <- function(X, Y) {
    # This function generates the probabilities for the Naive-Bayes-Classifier.
#
    # Args:
    # X: Matrix of features
# Y: Vector of labels
#
    # Returns:
# A list containing the following elements:
# $phiSpam: Probabilities for words occuring in SPAM message
# $phiHam: Probabilities for words occuring in HAM message</pre>
```

```
# $gammaSpam: The relative frequency of SPAM messages
# $gammaHam: The relative frequency of HAM messages

nWords <- length(Y)
indSpam <- as.logical(Y)
indHam <- !(indSpam)
NBClass <- list()

# Generate probabilities
NBClass$phiSpam <- (colSums(X[indSpam, ]) + 1) / (sum(X[indSpam, ]) + nWords)
NBClass$phiHam <- (colSums(X[indHam, ]) + 1) / (sum(X[indHam, ]) + nWords)

# Get relative frequencies
NBClass$gammaSpam <- sum(indSpam)
NBClass$gammaHam <- sum(indHam)

return(NBClass)
}</pre>
```

Zähler und Nenner wurden derart angepasst, dass für den Fall, dass keine Trainingsdaten vorliegen, für die bedingten Verteilungen der Wörter in einem Dokument a priori diskrete Gleichverteilungen mit Wahrscheinlichkeiten  $\frac{1}{|V|} = \frac{1}{2500}$  angenommen werden.

#### 1.4 Vorhersage auf den Testdaten

```
fnNBPredict <- function(X, NBClass) {</pre>
  # This function predicts one of the two classes (SPAM or HAM) for some test
  # data X using a Naive-Bayes-Classifier trained by fnNBTrain.
  # Args:
                Matrix of features
  # X:
      NBClass: A list returned by fnNBTrain which contains
                   $phiSpam: Probabilities for words occuring in SPAM message
  #
                               Probabilities for words occurring in HAM message
  #
                   $gammaSpam: The relative frequency of SPAM messages
                   $gammaHam: The relative frequency of HAM messages
  # Returns:
      A vector with predictions for each example.
  # Predict labels (using logarithm)
  postSpam <- rowSums(t(t(X) * log(NBClass$phiSpam))) + log(NBClass$gammaSpam)</pre>
  \verb|postHam| <- rowSums(t(t(X) * log(NBClass\$phiHam))) + log(NBClass\$gammaHam)| \\
  pred <- (postSpam > postHam) * 1
  return(pred)
}
# Predict test labels
predTest1 <- fnNBPredict(XTest, NBClass1)</pre>
```

```
# Number of errors
nErr1 <- sum(YTest[[1]] != predTest1)</pre>
```

Insgesamt gibt es lediglich 6 falsche Klassifikationen, was einer Fehlerrate von 2.31% entspricht.

Schauen wir uns an, welche Wörter besonders gute Indikatoren für SPAM oder HAM sind. Dazu betrachten wir jeweils die 25 Wörter mit den größten  $\Phi_{i|1}$  bzw.  $\Phi_{i|0}$ :

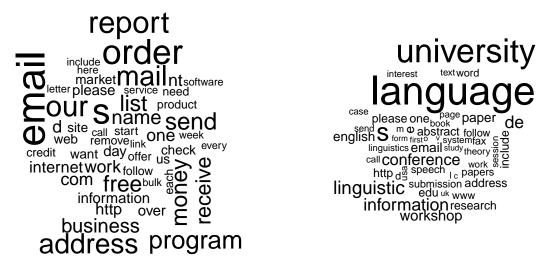


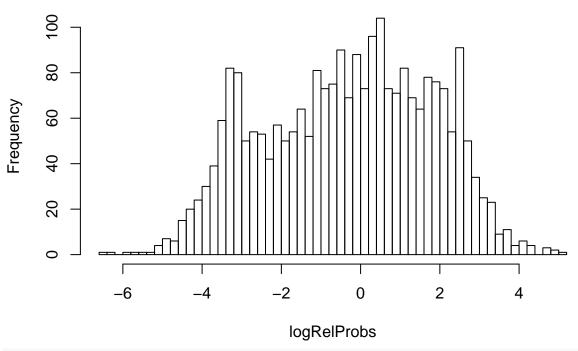
Figure 1: Wordclouds for SPAM (left) and HAM (right) indicators.

#### 1.5 Feature Engineering

Für die Klassifizierung von SPAM und HAM bedeutunglose Wörter sollten in SPAM- und HAM-Nachrichten relativ betrachtet ähnlich häufig vorkommen. Um Ähnlichkeit zu quantifizieren, können wir das Verhältnis von  $\Phi_{i|1}$  zu  $\Phi_{i|0}$  betrachten. Logarithmieren liefert eine bessere Skalierung.

```
logRelProbs <- log(NBClass1$phiSpam/NBClass1$phiHam)
hist(logRelProbs, breaks = 50)</pre>
```

## **Histogram of logRelProbs**



```
# Remove some words
indMeaningful <- !((logRelProbs >= (-1.5)) & (logRelProbs <= 1.5))

# Test classification after removal of meaningless words
NBClass2 <- fnNBTrain(XTrain[, indMeaningful], YTrain[[1]])
predTest2 <- fnNBPredict(XTest[, indMeaningful], NBClass2)

# New classification error
nErr2 <- sum(YTest[[1]] != predTest2)</pre>
```

Durch die Entfernung bedeutungsloser Wörtern hat sich die Anzahl der Fehler von 6 auf  ${\tt nErr2}$  halbiert.